



**POLYTECHNIQUE  
MONTRÉAL**

**INF8770 - Technologies multimédia  
Hiver 2024**

**TP 3**

**2045362 – Alexandre Marmen  
2060886 – Julien Roux**

### Question 1)

- a) On ne trouvera jamais une trame identique à une image JPEG puisque celle-ci est compressée avec perte. On pourra donc approximer mais ça ne sera pas une correspondance exacte. Étant donné que l'algorithme basique retournera toujours "out", le pourcentage de vidéos correctement trouvées correspond au pourcentage de résultats dont "out" est la solution. Précisément **19.5%**.
- b) La taille des 100 vidéos est de 423 Mo.
- c) On va prendre la moyenne des trames par seconde et la hauteur et largeur moyenne de trame de chaque vidéo et la multiplier par la durée totale des 100 vidéos. On obtient donc:

```
Analysis Summary:  
Total Videos Analyzed: 100  
Average FPS: 27.53  
Average Frame Width: 1280.00  
Average Frame Height: 720.00  
Total Duration (in seconds): 1402.75
```

$$27.53 \text{ T/s} * 1402.75 \text{ s} * (1280 * 720) \text{ pixels/T} * 24 \text{ bits/pixel} * 1 \text{ octet/8 bit} \simeq 106.77 \text{ Go}$$

On va supposer un taux de compression JPEG de 1.15:

$$106.77 \text{ Go} / 1.15 = 92.84 \text{ Go}$$

- d) On prend le résultat précédent sans compression JPEG, donc 106.77 Go.
- e) En b) on obtient la plus petite taille étant donné que le format mp4 compresse les vidéos selon la différence entre les blocs présents dans les trames et non leurs tailles réelles. La taille totale en c) est inférieure à celle obtenue en d) étant donné qu'on compresse les trames selon le format JPEG avec un taux arbitraire de 1.15, et la valeur en d) représente la taille réelle de toutes les trames, sans perte.

### Question 2)

#### Hypothèse 1:

Nous allons d'abord comparer l'impact des choix des N-images clefs, où dans un premier temps on prend toutes les images, et par la suite une image sur dix. Dans les deux cas on utilisera les paramètres constants suivants: l'espace colorimétrique RGB, la dimensionnalité 1D et la similarité cosinus.

En diminuant l'échantillon de l'indexation on s'attend à une meilleure efficacité au niveau du temps de calcul, qui par contre pourrait causer un plus faible taux de réussite et un écart de minutage plus important étant donné le manque d'information conséquent.

### Hypothèse 2:

Nous allons ensuite comparer l'impact de la mesure d'affinité, où dans un premier temps on mesure la similarité cosinus et par la suite la distance euclidienne. Dans les deux cas on utilisera les paramètres constants suivants: on prend toutes les images-clefs, l'espace colorimétrique RGB et la dimensionnalité 1D.

Cette hypothèse est intéressante étant donné que la similarité cosinus mesure la similarité directionnelle entre deux vecteurs peu importe leur magnitude tandis que la distance euclidienne mesure simplement la distance spatiale entre deux points dans un espace vectoriel sans prendre en compte la direction des vecteurs. On peut donc s'attendre à une meilleure précision pour la similarité cosinus mais à une plus faible efficacité de temps de calcul comparé à la distance euclidienne.

### **Question 3)**

| <b>Toutes les images, RGB, 1D, similarité cosinus</b> |        |
|-------------------------------------------------------|--------|
| Vidéos correctement retrouvées (%)                    | 86.20  |
| Écart temporel (s)                                    | 1.75   |
| Taux de compression (%)                               | 98.48  |
| Temps d'indexation des trames (s)                     | 257.71 |
| Temps de recherche d'une image (ms)                   | 354.37 |

| <b>Toutes les images, RGB, 1D, distance euclidienne</b> |        |
|---------------------------------------------------------|--------|
| Vidéos correctement retrouvées (%)                      | 78.5   |
| Écart temporel (s)                                      | 1.76   |
| Taux de compression (%)                                 | 98.48  |
| Temps d'indexation des trames (s)                       | 257.71 |
| Temps de recherche d'une image (ms)                     | 205.78 |

| Une image sur dix, RGB, 1D, similarité cosinus |        |
|------------------------------------------------|--------|
| Vidéos correctement retrouvées (%)             | 86.5   |
| Écart temporel (s)                             | 1.73   |
| Taux de compression (%)                        | 99.85  |
| Temps d'indexation des trames (s)              | 160.13 |
| Temps de recherche d'une image (ms)            | 59.42  |

Conclusion Hypothèse 1: On remarque qu'en effet le temps d'indexation (160.13s vs 257.71s) et de recherche d'image (59.42ms vs 354.37ms) est plus rapide pour une image-clé sur dix, cependant on observe des résultats légèrement meilleurs par rapport à l'écart temporel (1.73s vs 1.75s) et au taux de réussite des vidéos trouvées (86.5% vs 86.2%). Cela peut être expliqué par le fait qu'en prenant une image sur dix, on élimine considérablement du bruit et de la redondance entre les trames donc aide l'algorithme de recherche à trouver les bonnes correspondances. Cependant il est bon de noter que les écarts de valeurs sont assez proches et si on réduit plus le nombre d'images dans notre matrice de descripteurs les résultats tendraient à valider notre hypothèse sur le nombre d'images trouvé et l'écart de minutage .

Conclusion Hypothèse 2: En ce qui concerne l'hypothèse visant la mesure d'affinité, on voit bien les résultats attendus. C'est-à-dire que la similarité cosinus entraîne une meilleure précision que la distance euclidienne (86.2% vs 78.5%), cependant on perd de la performance dans le temps de recherche (354.37ms vs 206.78ms). L'hypothèse explique donc bien la provenance des ces résultats.

#### Question 4)

La première hypothèse choisie porte sur le poids du modèle, plus particulièrement ResNet-18 (44.7 MB) vs ResNet-50 (97.8 MB).

Étant donné que ResNet-50 est plus lourd que ResNet-18, on s'attend à ce qu'il soit plus précis et donne de meilleur résultat, en effet la différence de poids est lié au fait que ResNet-50 a plus de couche de neurones et qu'il a été entraîné avec plus de paramètres.

Cette meilleure précision vient avec une plus grande complexité de calcul donc ResNet-50 sera plus long à l'exécution.

En résumé, théoriquement ResNet-18 sera plus rapide et ResNet 50 donnera de meilleurs résultats (Images trouvés, minutage..).

La seconde hypothèse portera sur le nombre d'image-clefs, comme pour les descripteurs par histogramme de couleur on veut voir l'impacte de la réduction des images dans notre matrice de descripteurs sur la précision de la recherche de correspondance.

On peut s'attendre à ce que plus on réduit le nombre d'images-clefs, moins bon sera notre taux d'images trouvées bien qu'il soit possible que prendre une image clef sur 2 ou 3, n'impacte pas significativement cette métrique. On s'attend principalement à ce que plus on réduit le nombre d'images-clefs, plus l'écart de minutage augmentera car dans la sélection il est possible d'exclure la correspondance exacte avec notre jpeg, on aura donc nécessairement un écart de minutage.

On a s'attend surtout à ce que la recherche et l'indexation soit beaucoup plus rapide, en effet si on prend 1 image sur 2 on va diviser par 2 la taille notre matrice de descripteur et donc aussi les calculs de descripteurs. Puis étant donné une matrice deux fois moins grande dans laquelle faire la recherche, le temps pour trouver les correspondances sera plus rapide bien que moins significatif comme le calcul de la distance cosine est réalisée par un produit matriciel qui peut être réalisée très rapidement via le gpu.

Enfin on s'attend à ce que le taux de compression augmente si on prend moins d'images-clef car la matrice de descripteurs correspondantes sera moins grande.

### Question 5 et 6.a)

#### 1. ResNet 18 VS ResNet 50

On va faire une indexation de toutes les images avec un seul thread et un maximum de calcul sur le GPU et le calcul de distance se fait avec Cosine.

| modèle                   | ResNet 18 | ResNet 50 |
|--------------------------|-----------|-----------|
| Images trouvés (%)       | 95.5%     | 92.2%     |
| Écart minutage (s)       | 0.61      | 1.37      |
| Taux de compression      | 0.816     | 0.266     |
| Temps d'indexation (s)   | 556       | 835       |
| Temps recherche (ms/img) | 263       | 333       |

Il est possible que ResNet-50 soit moins bon que ResNet-18 dans le cas où sa complexité peut conduire à un surajustement, ce qui signifie que ResNet-50 pourrait être plus sensible au bruit ou aux variations mineures dans les données, affectant ainsi sa capacité à créer une même description pour une image jpeg de mauvaise qualité et sa version de bonne qualité. En

revanche, ResNet-18, étant moins complexe, pourrait être moins susceptible de surajuster et mieux généraliser, ce qui se traduirait par de meilleures performances dans ce cas particulier. Ainsi dans notre cas on se retrouve à obtenir des meilleures performances avec un modèle moins précis en théorie car la différence de qualité à moins d'impact.

Ainsi avec un banque d'image à chercher d'assez mauvaise qualité on obtient de meilleur résultats en termes de minutages et de pourcentage d'image trouvés avec le modèle ResNet 18.

En termes de rapidité comme prévu ResNet 50 est plus long pour l'indexation et recherche, car il nécessite plus de calcul pour produire le descripteur de l'image

Même chose pour le taux de compression, car ResNet 50 produit des vecteurs descripteurs de 2048 éléments alors que ResNet 18 en produit de 512, ce qui correspond bien au taux de compression de ResNet 50 environs 4x moins bon.

## 2. Nombre d'images-clefs

Pour calculer le descripteur on utilise le modèle ResNet 18, les calculs sont sur un seul thread, un maximum de calcul sur le GPU et le calcule de distance se fait avec Cosine.

| N images-clefs           | Toutes | 1 sur 2 | 1 sur 5 | 1 sur 10 | 1 sur 24 |
|--------------------------|--------|---------|---------|----------|----------|
| Images trouvés (%)       | 95.5%  | 95.5%   | 95.1%   | 94.6%    | 94.2%    |
| Écart minutage (s)       | 0.61   | 0.64    | 0.74    | 0.86     | 1.18     |
| Taux de compression      | 0.816  | 0.908   | 0.963   | 0.982    | 0.992    |
| Temps d'indexation (s)   | 556    | 341     | 218     | 143      | 119      |
| Temps recherche (ms/img) | 269    | 266     | 266     | 266      | 268      |

Les résultats sont fidèles à notre hypothèse, on voit bien que plus on réduit le nombre d'images-clefs plus le taux d'images trouvées diminue et l'écart de minutage augmente, même si les écarts sont plutôt faibles. En effet, entre **toutes les images** et **1 image sur 24** on a perdu 1% d'image trouvés et l'écart de minutage a augmenté d'environ 0.6s ce qui est assez faible. Cependant la baisse de temps d'indexation est beaucoup plus significative, par exemple entre **toutes** et **1 sur 2** images-clefs le temps d'indexation est presque divisé par deux pour un même taux d'images trouvés et une très faible augmentation de l'écart de minutage. Pour le temps de recherche, celui-ci ne varie pas ou pas significativement cela est probablement dû au fait que le temps de calcul du cosinus et de la recherche de la meilleure

correspondance à peu d'influence par rapport au calcule du descripteur de l'image jpeg à trouver.

Ces résultats montrent que si l'on peut accepter un peu moins de précision, réduire le nombre d'images-clefs a beaucoup d'influence sur le temps que prendra notre recherche.

### **Question 6.b)**

Avec la meilleure configuration pour chaque modèle et l'indexation de toutes les images.

Nous allons discuter de 3 cas qui apparaisse dans nos résultats, le premier cas est celui où seul l'algorithme à base d'histogrammes se trompe, le second est celui où seul l'algorithme à base de réseau de neurones se trompe et le dernier cas correspond a celui ou nos deux algorithmes se trompent.

#### **1er cas:**

Image jpeg dont l'on cherche la vidéo source : **i147.jpeg**



Image de la vidéo qui correspond : **v005.mp4**



L'histogramme s'est trompé de vidéo et a déterminé que l'image correspondante vient de **v082.mp4** à 1.85 seconde.



On remarque que l'algorithme par histogramme c'est fortement trompé. L'environnement, la vitesse de prise de vue sont très différents.



On remarque cependant certaines similarité de couleur, le gris clair du ciel dans les deux images, le noir/gris foncée de la terre de la coline sur le jpeg et sol de la vidéo avec la voiture et encore le marron du sol avec le maron du bâtiment.

De Plus quand on compare l'image jpeg et la vidéo correspondante, on remarque beaucoup de changement de couleur entre les deux, par exemple la terre de la colline qui passe du maron (vidéo) au noir (jpeg).

Ainsi comme l'algorithme par histogramme utilise seulement les couleurs des images pour faire la correspondance il possible que deux images même très différentes donnent des histogrammes de couleur très similaire, surtout dans notre cas les couleurs du jpeg sont très différentes de celle de la bonne image. C'est pourquoi dans le cas de cette image il a déterminé que la l'image de la v082 correspondait le plus au jpeg.

L'algorithme par réseau de neurones utilise l'information structurelle de l'image en plus de la couleur, il voit donc que même si les couleurs sont très différentes la structure de l'image est similaire entre le jpeg et la bonne vidéo.

## **2e cas:**

Image jpeg dont l'on cherche la vidéo source : **i363.jpeg**




Image de la vidéo qui correspond : **v005.mp4**



Le réseau de neurones s'est trompé de vidéo et à déterminé que l'image correspondante était **out**.

On peut expliquer cette erreur pas le fait que la structure de l'image à trouver est assez simple, surface blanc/bleu avec un peu de noir par endroit. Ainsi la mauvaise qualité de l'image jpeg fait penser au réseau de neurones que la structure de l'image est très différentes, notamment sur le jpeg on a des surfaces assez grandes et monochrome. Le réseau va donc pouvoir déterminer que ces surfaces monochrome et la grande surface correspondant à la neige sur l'image de la vidéo ne correspondent pas or comme on a beaucoup ce genre de surface sur le jpeg de mauvaise qualité, le réseau de neurones détermine que la structure des deux images est trop différentes ainsi la distance calculée avec le cosinus sera en dehors de notre seuil, puis comme les autres vidéos ne sont pas bonnes non plus il détecte cette image comme **out**.

Cependant l'histogramme détecte correctement l'image car en se basant uniquement sur les couleurs il n'est pas influencé par les modifications dans la structure.

### 3e cas

Image jpeg dont l'on cherche la vidéo source : **i396.jpeg**



Image de la vidéo qui correspond : **v041.mp4**



Les deux algorithmes ont déterminé que cette image était **out**, l'explication de cette erreur pour les deux algorithmes est respectivement la même que celle donnée pour les cas 1 et 2.

Soit pour le réseau, les surfaces monochrome du jpeg font paraître la structure de l'image comme trop différentes de celle de l'image de la vidéo. Et pour l'histogramme c'est la modification des couleurs de bases entre l'image de la vidéo et le jpeg qui crée cette erreur, notamment l'ours est "vert" sur le jpeg ce qui n'est pas/moins le cas sur l'image de la vidéo.